

字符串

黄建恒

广东实验中学

2026 年 4 月 24 日

Overview

- 1 哈希, KMP
- 2 ACAM
- 3 SA
- 4 SAM
- 5 Runs
- 6 基本子串结构

过一下算法

哈希, KMP, exKMP (Z函数), Manacher, AC 自动机, SA
*SAM, *PAM, *Lyndon, **Runs。
感兴趣可以研究一下基本子串结构 ()。

尝试一下

例 (qoj8079)

有一个字符串， q 次操作，每次在开头或末尾加入一个字符 x ，询问其最长 border 长度。

$q, x \leq 5 \times 10^5$ 。

s 有长为 len 的 border 等价于 s 有长为 $|s| - len$ 的周期。

称第 i 次操作后的串是 s_i ，不难发现，假如 s_i 的答案是 j ，那么 s_{i-j} 是 s_i 的周期。

注意 s_x 作为周期的时间是一段区间，可以使用二分找到这个区间，使用哈希 check，时间复杂度 $O(q \log q)$ 。

尝试一下

例 (P10716)

你有一个字符串 S 。 q 个询问，每次给出 (i, k) ，求有多少个非空字符串 A ，使得存在可空字符串 $B_1, B_2, \dots, B_{k-1}$ 满足：

$$S[1, i] = AB_1AB_2A \dots AB_{k-1}A$$

其中 $S[1, i]$ 表示 S 的长度为 i 的前缀。

$1 \leq k \leq i \leq n \leq 2 \times 10^5$ ， $1 \leq q \leq 2 \times 10^5$ ， S 仅包含小写字母。

若 $k \neq 1$, 则要求 A 是 $S[1, i]$ 的 border, 即 $|A|$ 是 i 在失配树上的祖先, 且 A 在 $S[1, i]$ 中不重叠的出现至少 k 次。

考虑对每个 j , 贪心找到最靠前的不重叠出现的位置, 总个数是调和级数 $O(n \ln n)$ 。这些位置满足 $LCP(S, S[pos, n]) \geq j$ 。按 j 扫描线, 需要维护仍然合法的集合, 支持 n 次删除, $O(n \log n)$ 次查询后继, 可以使用并查集, 做到 $O(n \alpha(n) \log n)$ 。

查询时也扫描线, 倍增即可。这部分 $O(q \log n)$ 。

尝试一下

例 (AGC064C Erase and Divide Game)

Takahashi 和 Aoki 玩游戏。先在黑板上写若干个数，由 N 个互不相交的区间 $[l_i, r_i]$ 组成。

两人轮流操作，每次操作先删去所有的奇数/偶数，再把剩下的数除以 2（向下取整），无法操作的人输。

Takahashi 先手，假设两人都采用最优策略，问谁能获胜。

$n \leq 10^4, 0 \leq l_i \leq r_i \leq 10^{18}$

把所有数从低往高位建出一个 Trie，从根节点往下走，先走到空节点的人获胜，我们希望用尽量少的节点去概述这棵树。

考虑把 $[l_i, r_i]$ 拆分成 $O(\log V)$ 个区间，每个区间长为 2^k ，可以视为一棵满二叉树的每个叶子下面接同一形态的链，即前 k 步随便走，后面要按一条链走。

将不同长度的区间分层，每层从低位往高位建出按一条链的部分（即建出 $\log V$ 棵 Trie 树）。

我们尽可能用区间短的层的点，如果这层不能用，我们就往下一层跳，相当于随便走的步数 $+1$ ，链长 -1 ，这非常类似于 AC 自动机。

设一个点的 *fail* 是其最近一层的和它一个后缀相同，且深度差等于层数差的点，处理出每层根节点的 *fail*，然后就可以正常用 bfs 求出所有节点的 *fail* 和 $tr_{0/1}$ 。

时间复杂度 $O(n \log^2 V)$ 。

对字符串 $u = u_1 \dots u_n$, 令 $\text{pre}(u, i)$ 表示前缀 $u_1 \dots u_i$ 。特别地, $\text{pre}(u, 0)$ 是空字符串。对于两个字符串 $u = u_1 \dots u_n$ 与 $v = v_1 \dots v_m$, 令 $u + v$ 表示连接后的字符串 $u_1 \dots u_n v_1 \dots v_m$ 。

给定长度为 m 的字符串 $t = t_1 \dots t_m$ 和一棵有 $(n + 1)$ 个节点的树 T , 节点编号为 $0, 1, \dots, n$, 其中节点 0 是根。每条边上都有一个字符。请注意, 在本题中, 字母表中可能会有多于 26 个字符。

考虑如下函数 $f(i, j) = \max\{d(x) \mid s_x \text{ 是 } s_i + \text{pre}(t, j) \text{ 的后缀}\}$, 其中 s_i 是从根到节点 i 的最短路径上所有字符连接而成的字符串, $d(i)$ 是从根到节点 i 的最短路径经过的边数。

你需要求出 $g_1, \dots, g_m$, 其中 $g_j = \sum_{i=1}^n f(i, j)$ 。

注意: s_0 是空字符串, 而空字符串是任何字符串的后缀。

$$\sum n, \sum m \leq 2 \times 10^5, \text{ 字符集 } 1 \sim n$$

首先给出一个简单平方做法。建立 AC 自动机。枚举 i ，扫 t 的所有字符，在 AC 自动机上走，经过的所有点的深度即为 $f(i, j)$ 。

那么考虑对于一个点 i ，找到它第一次跳 fail 的位置，假设是在第 t 个字符跳到了点 u ，那么如果 u 的深度 $\geq t$ ，后续部分和从 $jump(u, t)$ 出发一样，其中 $jump(u, t)$ 表示从 u 往上跳 t 次父亲得到的点。如果 u 的深度 $< t$ ，那么后续部分和从根出发一样。

如果是第一种情况， i 和 $jump(u, t)$ 给答案 g_i 贡献的答案只有一个前缀有区别，且区别是一个定值。如果是第二种情况，就需要提前加上前 t 次的贡献，加上从根出发的贡献，再记录一下 u 的深度，表示要扣掉从根出发的前 t 次的贡献。

可以维护一个 d_i 表示当前扫过的点中有多少个贡献等价于从 i 出发。然后转移就是 $d_{jump(u, t)} + = d_i$ ，且让 g 的一个前缀加上一个定值乘上 d_i 。

最后一路维护上去变成一堆和根相关的贡献。记一下每个深度的出现次数。算一下根的每个 j 的答案。可以线性处理。

总时间复杂度 $O((n + m) \log n)$ 。

尝试一下

例 (CF1913F Palindromic Problem)

给定一个长度为 n 的字符串 S 。你可以将至多一个字符替换为任意小写字母，求这样操作一次之后串中回文子串数量的最大值。 $n \leq 3 \times 10^5$

枚举修改位置 i 和修改为的字符 c ，考虑增加量和减少量。减少量可以通过 Manacher 简单算出。增加量可以预先枚举回文中心，回文的极长端点 l, r 必有一个被修改。修改后的增加量可以 SA 求出。

尝试一下

例 (P9623 Baby's First Suffix Array Problem)

多次询问 (l, r, k) ，求区间子串 $S[l, r]$ 的一个后缀 $S[k, r]$ 在该区间的排名 (SA rank 数组) $n, q \leq 5 \times 10^4$

先求出全局的 SA 数组，考虑变成区间时发生的变化。

1. $rk_j > rk_k$, $S[j, r]$ 是 $S[k, r]$ 的前缀，即 $LCP(j, k) \geq r - j + 1$
 考虑分治，每次对 rk 跨过 mid 的 j, k 计数，相当于 j, k 到 mid 的 $height \geq r - j + 1$ ，是一个二维偏序，时间复杂度 $O(n \log^2 n)$ 。
2. $rk_j < rk_k$, $S[k, r]$ 是 $S[j, r]$ 的前缀，即 $LCP(j, k) \geq r - k + 1$ ，同理，总时间复杂度 $O(n \log^2 n)$ 。

尝试一下

例 (ARC175F Append Same Characters)

给 n 个串，有两种操作，代价均为 1。

1. 给每个串后面加一个字符 c 。

2. 交换相邻两个串。

求使得串的序列单调不降需要的最小代价，串有可能相同。

$n \leq 3 \times 10^5, \sum |S_i| \leq 3 \times 10^5, |\Sigma| = 26$

题目即要求往每个串 S_i 后接一个串 X ，最小化逆序对个数加 $|X|$ 。
考虑 S_i 和 S_j 的大小关系什么时候可能发生变化，不妨设 $S_i < S_j$ ，则
要求 S_i 是 S_j 的一个前缀，且令 Y 表示 S_j 去掉 S_i 这个前缀后得到的
串，则有 $X > YX$ 。

引理 1: $\text{cmp}(X, YX) = \text{cmp}(X, Y^\infty)$

引理 2: $\text{LCP}(X, YX) = \text{LCP}(X, Y^\infty)$

设 $n = |X|, m = |Y|, A = \sum X_i x^i, B = \sum Y_i x^i$

$$A - (B + Ax^m) = C$$

$$\Leftrightarrow A(1 - x^m) - B = C$$

$$\Leftrightarrow A - \frac{B}{1 - x^m} = \frac{C}{1 - x^m}$$

C 和 $\frac{C}{1-x^m}$ 的最低位相同, 且其正负性即 $\text{cmp}(X, YX)$ 。□

注意到 Y 只能是某个 S_i 的后缀, 因此我们可以对所有串建出 Trie 树辅助求出所有可能的 Y 及其出现次数, 将这些 Y 按 Y^∞ 排序。

引理 3: $cmp(XY, YX) = cmp(X^\infty, Y^\infty)$

引理 4: 若 $XY \neq YX$, 则 $LCP(XY, YX) = LCP(X^\infty, Y^\infty)$

设 $n = |X|, m = |Y|, A = \sum X_i x^i, B = \sum Y_i x^i$

$$A + Bx^n - (B + Ax^m) = C$$

$$\Leftrightarrow A(1 - x^m) - B(1 - x^n) = C$$

$$\Leftrightarrow \frac{A}{1 - x^n} - \frac{B}{1 - x^m} = \frac{C}{(1 - x^n)(1 - x^m)}$$

C 和 $\frac{C}{(1-x^n)(1-x^m)}$ 的最低位相同, 且其正负性即 $cmp(XY, YX)$ 。□

因此我们可以通过 SA 数组辅助把所有后缀 Y 按 Y^∞ 排序, 每次我们希望 $Y_1^\infty < X \leq Y_2^\infty$, 则 $|X| \geq LCP(Y_1^\infty, Y_2^\infty)$, 时间复杂度 $O(n \log n)$

<https://qoj.ac/contest/2550/problem/4878>

<https://uoj.ac/problem/889>

尝试一下

例 (CF1276F Asterisk Substrings)

给定一个字符集为小写字母的长度为 n 的字符串 s , 设 t_i 表示将 s 中的第 i 个字符替换为特殊字符 $*$ 时得到的字符串, 比如当 $s = abc$ 时, $t_1 = *bc$, $t_2 = a*c$, $t_3 = ab*$ 。

求字符串集合 $\{s, t_1, t_2, t_3, \dots, t_n\}$ 中本质不同的子串个数 (需要计算空串)。

注意 $*$ 仅表示一个字符, 不表示其他含义 (如通配符)。

$n \leq 10^5$

我们可以分成 4 种情况: $S, S^*, *S, S^*T$ 。

前三种情况可以简单解决, 对于 S^*T , 注意到同一个等价类的点 S 的贡献一样, 均为以某个 $endpos(S) + 2$ 为开头的 T , 我们要求出这些本质不同的 T , 即原串一些后缀的本质不同的前缀个数。

考虑建出反串 SAM, 可以对每个后缀排序, 用总长度减去相邻两个串的 LCP,

将每个后缀在反串 SAM 上的点按 dfn 排序, 则可以用线段树合并维护相邻的串, 两个串的 LCP 即为两个点的 LCA 的 len。

时间复杂度 $O(n \log n)$

例 (P11150 【THUWC 2018】字胡串)

给定一个长度为 n 的字符串 S 。 q 次询问，每次给定一个非空字符串 T ，求最小的 x 满足 $S[1, x] + T + S[x + 1, n]$ 的字典序最小。

$1 \leq n \leq 10^6$, $1 \leq Q \leq 5 \times 10^5$, $1 \leq \sum |T| \leq 10^6$ ，保证字符串仅由数字构成，即 $|\Sigma| = 10$ 。

最小化字典序即先最小化 $S[1, i] + T[1, j] < S[1, i + j]$ 的 $i + j$ ，然后最小化 T_j 。最后再最小化 i 。为了确保有解，先往 S 后加入一个最大字符。

考虑对 S 建 SAM，枚举 j 和 $S[i + j]$ ，即在 SAM 上走路，不难求出这个串在 S 中出现的最小位置。然后可以找到一些可能的答案。

接下来需要比较这些答案，如果两个后缀 $T[j_1, n], T[j_2, n]$ 是前缀关系，那么他们对应修改后的串一定是相等的，否则可以直接比较出大小关系。使用二分哈希即可。

虽然这个东西 NOI 应该不考。但还是会出现在 CTT 以及 XCPC。

构造：对每个后缀 s_l ，找到后面第一个比它小的后缀 s_r 以及（将字符串后面视为 $+\infty$ ）后面第一个比它大的后缀 $s_{r'}$ ，然后对这个区间进行拓展。得到 runs。

结论：每个周期串只会出现在其最小整周期作为 p 的一个 runs 中。

$\sum r - l + 1 - 2p = O(n \log n)$ ，本质不同的回文

练习：QOJ 15502, QOJ 17423,（可以用 runs 写一遍优秀的拆分）

定义一个串是双回文串当且仅当可以拆分为两个**非空**回文串。
计算一个小写字母串的双回文子串个数。

$$n \leq 5 \times 10^5。$$

计算拆分个数是简单的，只需计算每个点开头和结尾的回文串个数。
 考虑一个串什么时候有多个拆分。 $s = p_1 p_2 = q_1 q_2$ 满足 p_1, p_2, q_1, q_2 都是回文串。

引理 1: $s = pt$ 满足 s, p 回文当且仅当 $|t|$ 为 s 周期。

Proof. $s_i = s_{|p|-1-i} = s_{|s|-|p|+i} = s_{|t|+i}, \forall 1 \leq i \leq |p|$ 。 Qed.

于是令 $p_2 = p_1 t$ ，得到 $|t|$ 是 p_2 周期，同理 $|t|$ 是 q_1 周期。于是 $|t|$ 是 s 周期。

又 $s_i = s_{|p_2|-i+1} = s_{|s|+|p_1|-|p_2|+i} = s_{|s|-|t|+i}$ （先后用 p_2, q_1 翻转）于是 $|s| - |t|$ 是 s 周期。根据弱周期引理， s 有整周期 $\gcd(|t|, |s| - |t|)$ 于是一个串有多个拆分要求一个串有非平凡整周期。

定义一个串是弱双回文串当且仅当其可以拆分为两个可空回文串。

引理 2: 对于一个有非平凡整周期串 t 的字符串 s , s 是双回文串当且仅当 t 是弱双回文串。

必要性: 考虑 s 的一个划分 p, q 将其中一个 t 切割为 a, b , 证明 a, b 是回文串

充分性: 对于 t 的一个划分 a, b , 令 $q = b$, $s = pq$, 证明 p 回文串。(若 b 空, 改令 $p = a$)

且可以说明, 若 s 双回文, s 的统计次数为 $|s|/|t|$, 如果更多, 说明有更小的整周期串

建出 runs, 对每个 (l, r, p) 统计即可

还有最后一个问题：怎么判断一个区间是双回文串？可以证明，如果是双回文串，要么前缀是 l 开头不到 r 的最长回文串，要么前缀是 r 结尾的不到 l 的最长回文串。


总时间复杂度 $O(n \log^2 n)$ ，好像说本质不同的本原平方串只有 $O(n)$ 个，那去重后可以做到 $O(n \log n)$

大概率不会讲，一时半会也很难讲明白。大家可以对着博客学习一下。

基本子串结构

<https://www.cnblogs.com/crashed/p/17382894.html>

$ext(t)$ 为子串 t 的最长拓展串满足 $occ(ext(t)) = occ(t)$, 存在且唯一。
将 ext 相等的串视为等价类, 满足 $ext(t) = t$ 的串称为该等价类的代表元, 每个等价类形成一个阶梯形,
以 l 为横坐标, r 为纵坐标, 则左上对齐, 右下为阶梯形。



每个等价类的一行即代表 r 相等的一些串，即行等价类，对应正串 SAM 的一个节点。同理每个等价类的一列对应反串 SAM 的一个节点，因此等价类的周长和是 $O(n)$ 的。

基本子串结构

考虑如何表示一个等价类，
我们可以只建正串 SAM，注意同一个等价类中相邻两行可以用 SAM 的 DAG 去做转移，每次相当于从一个点 u 走一条转移边到 v 满足 $occ(u) = occ(v)$ ，这时 u 必然只有这一条出边，因此可以形成若干条链，每条链即代表一个等价类。

基本子串结构

如果要将反串的等价类和正串的等价类对应，我们只需要把正串的链底拿出来在反串上定位，时间复杂度 $O(n \log n)$ 。

如果对时间复杂度要求较高，可以在正串 DAG 上 dfs，在反串上前加字符，每次只走 $len(v) = len(u) + 1$ 的边，这样只会走到每个等价类代表的最长字符串，可以做到 $O(n)$ 。

然后要给非代表元打上标记，可以用之前求出的链进行上传，也可以直接按编号从大往小进行传递。

尝试一下

例 (CF1817F Entangled Substrings)

给定字符串 s 。

s 的非空子串对 (a, b) 合法，当且仅当存在可空字符串 c ，使得每次 a 在 s 中出现，后面都紧跟着 cb ；且每次 b 在 s 中出现，前面都紧跟着 ac 。即 a, b 只以 acb 的形式在 s 中出现。

求 s 的合法非空子串对数量。

$1 \leq |s| \leq 10^5$ 。

相当于统计一个等价类中的相离节点对数。

可以只建正串 SAM，对每段链分别统计，链上每个点代表 r 相同的行等价类，因此只用对每个点 u 统计有多少点的 $l > r(u)$ 。

由于等价类成阶梯形，每个行等价类 u 允许的最大 $l(u) = r(u) - \text{len}(\text{fail}(u))$ 是单调的，使用双指针扫一下即可，时间复杂度线性。

尝试一下

例 (uoj577 打击复读)

给两个数组 wl_i, wr_i 和一个字符串 s ，定义子串 $s[i, j]$ 的权值为其在原串每个匹配位置左端点的 wl 之和与与其在原串每个匹配位置右端点的 wr 之和的乘积，要支持 wl 单点修改，查询 s 所有子串的权值和（不要求本质不同）。

$n, q \leq 5 \times 10^5$ 。

即要把每个 wl_i 的系数算出来。

考虑对基本子串结构的每个等价类做统计，将正反串的等价类合并，仍然考虑阶梯形的性质，从大往小枚举 l ，对应的合法 r 是一段后缀，且单调。


预先将每个行等价类的 wr 之和算出来，使用双指针逐个加入合法的行等价类，即可算出每个列等价类的系数，再下放到每个位置即可。时间复杂度 $O(n + m)$

尝试一下

例 (uoj697 广为人知题)

给一个长为 n 的字符串 s ，再给 m 个模式串 $s[tl_i, tr_i]$ 。
 q 次询问 m 个模式串在子串 $s[ql_i, qr_i]$ 中出现次数。
 $n \leq 4 \times 10^5, m \leq 10^6, q \leq 10^5$ 。

只用考虑每个串所在等价类即可，修改为在每个等价类对应位置 $+1$ 。
 询问即求以 ql, qr 为左上角的矩形和。



考虑将贡献分为 3 部分，
 白色部分即同一等价类，可以用二维数点解决，
 蓝色部分是若干列等价类到 fail 树根的权值和，可以两次前缀和解决，
 绿色部分的左上角一定是某一等价类的最左列等价类的某个点，个数是 $O(n)$ 的，同样可以用两次前缀和解决。
 时间复杂度 $O(n + (m + q) \log n)$ 。

QOJ 9639 字符串 (可以尝试 $n \log n$)

CF1393E2 Twilight and Ancient Scroll (harder version)

P4482 Border 的四种求法

P8351 子串统计

完结撒花!